

OS Agent 记忆优化及高效应用研究

多源融合偏好与知识记忆优化技术方案报告

题目编号：XA-202612

发榜单位：麒麟软件有限公司

参赛单位：【TODO：学校 / 单位全称】

队伍名称：【TODO：队伍名称】

队伍成员：【TODO：成员姓名】

指导教师：【TODO：指导教师姓名】

2026 年 9 月

目录

1	引言与需求分析	2
1.1	题目背景	2
1.2	需求分析	2
1.3	赛题要求覆盖总览	2
1.4	方案核心思路	2
1.5	报告组织	4
2	总体架构设计	4
2.1	设计原则	4
2.2	三层记忆总体架构	4
2.3	双库架构：偏好库与知识库	5
2.4	代码组织	5
2.5	运行时存储布局	5
3	核心算法设计	6
3.1	多源偏好记忆：提取、版本化与跨场景适配	6
3.1.1	数据模型	6
3.1.2	三路提取器	6
3.1.3	版本化管理	6
3.1.4	跨场景适配与回溯	7
3.1.5	接入状态	7
3.2	知识记忆：结构化整合、冲突处理与关联检索	7
3.2.1	数据模型	7
3.2.2	新旧知识冲突处理	7
3.2.3	关联检索	8
3.2.4	可复用模板生命周期	8
3.3	敏感信息识别与精准遗忘	9
3.3.1	敏感信息识别与过滤	9
3.3.2	两阶段精准遗忘协议	9
3.4	端侧语义检索：可插拔嵌入与轻量向量库	10
3.4.1	可插拔嵌入后端	10
3.4.2	轻量化向量存储	10
4	记忆流转机制：与短期、中期记忆的交互逻辑	10
4.1	短期 → 中期：压缩退役网关	10
4.2	中期记忆存储接口	11
4.3	长期记忆注入短期上下文	11

目录	2
4.4 中期 → 长期晋升	11
4.5 偏好与知识管道的流转关系	12
5 技术实现方案	12
5.1 实现栈与工程约束	12
5.2 Agent 主循环接线点	12
5.3 知识记忆工具面	12
5.4 配置面	13
5.5 质量保障	13
6 端侧部署与银河麒麟适配	14
6.1 端侧轻量化设计	14
6.2 银河麒麟 embedding SDK 接入	14
6.3 安装部署指南	14
6.4 操作说明	15
6.5 银河麒麟桌面操作系统适配测试报告	15
7 效果验证报告	15
7.1 评测指标定义与口径	15
7.2 标准化测试数据集说明	16
7.3 量化指标结果	16
7.4 对比实验设计（消融）	16
7.5 功能验收测试	17
7.6 历史基线与重测计划	17
7.7 检索延迟实测方案	17
8 真实场景应用案例	17
8.1 场景设计：开发助手日常使用（办公自动化）	17
8.2 实测记录	19
8.3 应用价值	19
9 总结与优化方向	19
9.1 已完成工作	19
9.2 待完成事项	19
9.3 后续优化方向	20

1 引言与需求分析

1.1 题目背景

基于麒麟操作系统的 OS Agent 是智能交互系统的核心组件，其记忆模块中的**偏好记忆与知识记忆**是支撑个性化服务适配、知识沉淀复用的核心载体。当前两类记忆面临的问题具有多源性。一方面，**工具调用执行结果结构化不足、数据质量参差不齐**，导致偏好提取（如工具选择偏好）不精准、知识沉淀不高效；另一方面，**其他数据源的问题相互叠加**——用户行为捕捉不全面、跨场景数据不一致、配置版本混乱——最终形成动态偏好提取偏差、版本化管理效率低、新旧知识冲突滞后、关联检索精度有限等痛点。

本方案针对上述痛点，面向麒麟操作系统 OS Agent 交付一套**多源融合偏好与知识记忆优化解决方案**，具备偏好精准捕捉、知识智能整合、高效检索复用等核心功能，并满足端侧轻量化部署与数据安全合规要求。

1.2 需求分析

赛题聚焦两大核心问题，本方案将其分解为五项技术需求。（1）**偏好记忆的动态捕捉与适配**：以工具调用执行结果为核心数据源，结合用户行为数据与手动配置，实现用户操作习惯、输出风格、安全策略等偏好的精准提取、版本化更新与跨场景复用；（2）**知识记忆的结构化整合**：新旧知识冲突处理、关联检索优化，支持工作流程知识、历史案例、可复用模板的结构化存储与智能调用；（3）**端侧部署约束**：调用银河麒麟国产桌面操作系统 embedding SDK，轻量化存储，检索响应延迟 $\leq 500\text{ms}$ ；（4）**安全合规**：敏感信息识别与过滤，自然语言指令驱动的精准确忘；（5）**记忆流转**：与短期、中期记忆间的数据流转兼容。

1.3 赛题要求覆盖总览

表 1 给出赛题七项内容要求与本方案的对应关系及当前状态；表 2 给出四项性能指标的覆盖状态。**所有未实测 / 待完成项均以红色 TODO 标出**，详见第 7 章效果验证报告。

1.4 方案核心思路

本方案的设计思路可概括为四点。其一是**确定性优先的记忆算法**：偏好提取与知识冲突处理均采用可解释的规则与统计阈值（无 LLM 依赖），行为可审计、结果可复现，契合端侧资源约束。其二是**只追加的版本化**：偏好与知识均以版本链存储，回滚与回溯是非破坏性操作，天然支持跨场景适配与按时间点回溯。其三是**隐私内建**（privacy by construction）：所有记忆入库边界统一经过敏感信息脱敏，遗忘操作采用「预览—人工确认—物理删除—残留复验」两阶段协议。其四是**可插拔嵌入与轻量存储**：嵌入后端按

表 1: 赛题内容要求覆盖对照

编号	赛题内容要求	本方案对应模块	状态
(1)	多源数据整合（工具结果 / 用户行为 / 手动配置，清洗、标准化、质量校验）	三路偏好提取器 + 隐私脱敏边界 (§3.1)	部分实现
(2)	偏好记忆动态捕捉（自动提取、版本化管理、跨场景适配与回溯）	偏好版本链 + 场景标签机制 (§3.1)	部分实现
(3)	知识记忆结构化整合（冲突处理、关联检索、模板沉淀）	SPO 事实库 + 六动作冲突处理 + 模板生命周期 (§3.2)	已实现
(4)	端侧部署（麒麟 embedding SDK、轻量存储、延迟 $\leq 500\text{ms}$ ）	可插拔嵌入后端 + int8 量化向量库 (§3.4、§6)	部分实现
(5)	敏感信息识别过滤 + 自然语言精准遗忘	六类检测器 + 两阶段遗忘 (§3.3)	已实现
(6)	与短期 / 中期记忆的数据流转	压缩退役网关 + 三层记忆架构 (§4)	部分实现
(7)	量化评测机制与测试报告	四指标评测框架 (§7)	待完成

表 2: 性能指标覆盖对照

性能指标	目标值	本方案现状
偏好提取准确率	$\geq 85\%$	算法已实现，量化实测 TODO
知识检索召回率	$\geq 85\%$	检索机制已实现，量化实测 TODO
知识检索响应时间	$\leq 500\text{ms}$	线性扫描复杂度分析见 §3.4，实测 TODO
知识冲突处理正确率	$\geq 88\%$	六动作机制已实现，量化实测 TODO

配置在 remote / local / kylin 三者间切换，向量库采用 int8 量化与单文件 JSON 持久化，无外部服务依赖。

1.5 报告组织

第 2 章总体架构；第 3 章核心算法设计；第 4 章记忆流转机制；第 5 章技术实现方案；第 6 章端侧部署与银河麒麟适配；第 7 章效果验证报告；第 8 章真实场景应用案例；第 9 章总结与优化方向。

2 总体架构设计

2.1 设计原则

架构设计遵循四项原则。**无 LLM 依赖的记忆内核**：偏好提取、冲突处理、遗忘判定均为确定性规则与统计阈值，不引入额外推理开销，适合端侧部署，且每一步决策可解释、可审计。**单一职责的 crate 划分**：领域类型、存储、服务逻辑、接入管道分层清晰，便于按需裁剪与移植。**文件即数据库**：全部记忆状态持久化为工作区 .amadeus/ 目录下的 JSON 文件，零外部服务依赖，便于备份、检视与迁移。**安全边界前置**：敏感信息检测与脱敏发生在一切入库边界，而非事后清理。

2.2 三层记忆总体架构

系统沿用「短期—中期—长期」三层记忆模型（图 1）：




图 1：三层记忆架构与数据流转（短中期之间经 ContextGate 网关；红色虚线为待实现的晋升路径）

三层记忆的分工如下。**短期记忆**是活跃会话的上下文窗口（Agent.history）与压缩摘要，生命周期为单会话；**中期记忆**是跨会话的记录数据库，沉淀任务、决策、文件状态、错误与解决方案、状态快照 (§4)；**长期记忆**则涵盖用户事实（memory.json）、结构化知识库（structured_memory.json）、偏好库（preferences.json）与语义索引（rag_index.json），经 MemoryRegistry 注入系统提示词。

2.3 双库架构：偏好库与知识库

偏好与知识两类记忆分别由独立仓库管理，共享统一的隐私脱敏边界（图 2）。




图 2: 多源数据接入与偏好 / 知识双库（红色虚线框为待接线部分）

2.4 代码组织

记忆子系统在 Rust 工作区内按职责划分为独立 crate（表 3）。

表 3: 记忆子系统代码组织

crate	职责	关键内容
memory-domain	领域类型	事实版本、片段、关联边、模板的纯数据模型
memory-service	知识库服务	冲突处理、关联检索、模板生命周期、两阶段遗忘
memory	中期记忆	记录模型、存储接口、上下文网关（ContextGate）
context（preference 模块）	偏好库	三路提取器、版本化、场景标签与回溯
privacy	隐私保护	六类敏感信息检测器与脱敏
rag	语义检索	可插拔嵌入后端、int8 量化向量库、RagTool
core（memory_wiring 等）	接线	agent 主循环与记忆系统间的数据管道

2.5 运行时存储布局

全部状态位于工作区 .amadeus/ 目录（表 4），单文件 JSON、人可直接检视，符合端侧轻量化与可审计要求。

表 4: 运行时存储文件

文件	内容
.amadeus/preferences.json	偏好库：偏好条目及其版本链、场景标签
.amadeus/structured_memory.json	知识库：事实版本链、片段、关联边、模板
.amadeus/mid_term_memory.json	中期记忆库：网关产出的五类记录
.amadeus/memory.json	长期用户事实（MemoryRegistry 数据源）
.amadeus/rag_index.json	语义向量索引（v2 信封格式，支持 int8 量化）

3 核心算法设计

3.1 多源偏好记忆：提取、版本化与跨场景适配

3.1.1 数据模型

偏好条目 `StoredPreference` 由键、类别、置信度、场景标签与**版本链**构成。类别覆盖赛题要求的三类偏好并扩展为六类（表 5）。

表 5: 偏好类别划分

类别	语义
<code>ToolChoice</code>	工具选择偏好（同任务下倾向使用哪个工具）
<code>OutputStyle</code>	输出风格偏好（格式、详略、语言习惯）
<code>SafetyPolicy</code>	安全策略偏好（敏感操作授权习惯、避免清单）
<code>Workflow</code>	工作流偏好（常用步骤顺序）
<code>Habit</code>	重复操作习惯
<code>General</code>	其他通用偏好

3.1.2 三路提取器

针对赛题要求的三类数据源分别实现确定性提取器（表 6），全部为规则与统计阈值驱动，无 LLM 调用。

置信度由样本计数与信号一致性映射：样本越充分、信号越一致，置信度越高；连续失败与用户纠正均以固定步长衰减，使偏好可随行为漂移而退化。

3.1.3 版本化管理

版本链采用**只追加**策略：任何更新都生成新版本而非改写历史。`push_version` 负责追加版本，历史版本完整保留；`rollback` 是非破坏性回滚——生成一个「恢复为旧值」的新版本而非删除；`versions()` 提供完整版本史查询；`resolve_as_of(t)` 则按任意时间点回溯当时生效的版本，支持审计与复盘。

表 6: 多源偏好提取器

数据源	触发条件与产出	产出类别
工具执行结果	按(任务, 工具)聚簇统计成功 / 失败 / 延迟; 样本数 ≥ 2 、成功率 ≥ 0.8 且使用占比 ≥ 0.6 时生成 <code>tool_choice::task</code> 偏好; 同簇连续失败 ≥ 2 次则对该工具降权(置信度 -0.15 , 不删除条目)	ToolChoice
用户行为数据	同一动作重复 ≥ 2 次沉淀为 <code>habit::</code> 偏好; 检测到用户纠正行为时生成 <code>avoid::</code> 偏好并削弱与之冲突的习惯; 安全敏感动作归入安全策略	Habit / SafetyPolicy
手动配置信息	配置项直接生成 <code>config::</code> 偏好(置信度 0.98), 按键名关键词推断类别	全类别

3.1.4 跨场景适配与回溯

每个偏好可携带场景标签 (ScenarioTag: 场景名 + 属性键值对)。解析当前生效偏好时按两级匹配: 第一级由 `resolve_for_scenario` 优先取场景完全匹配的版本, 无则回退默认场景; 第二级由 `cross_scenario_candidates` 按场景属性集合的 Jaccard 相似度排序, 跨场景推荐最相近场景下已验证的偏好, 实现「跨场景复用」。

3.1.5 接入状态

工具执行结果管道已接入 agent 主循环(每次工具调用后即时提取); 用户行为与手动配置两路提取器已实现, 生产接线 **【TODO: 用户行为 / 手动配置管道接入 agent 主循环】**; 学到的偏好注入提示词 **【TODO: 偏好注入系统提示词 (闭环演示)】**。

3.2 知识记忆: 结构化整合、冲突处理与关联检索

3.2.1 数据模型

知识库(memory-service)由四类要素构成。FactVersion 是 SPO 三元组(主语—谓语—宾语)附加上下文、版本号与 `supersedes_id` 指针, 构成可追溯的版本链; Episode 为历史片段, 含内容哈希与敏感级别, 是模板证据的唯一合法来源; AssociationEdge 表示知识条目间的关联边, 参与检索加分; MemoryTemplate 承载可复用 workflow 模板(前置条件、步骤、输入 schema、证据链、成功率、版本、状态)。

3.2.2 新旧知识冲突处理

新事实入库时先做中文同义归一化 (canonicalize, 如「住址 / 地址」统一为 address), 再与既有事实判定冲突关系, 按表 7 六种动作处置。

表 7: 冲突判定与六种处置动作

动作	触发条件	处置
Add	无既有相关事实	新增版本链
Reinforce	同 SPO 且上下文一致	置信度 +0.05 (设上限), 不新增版本
Merge	宾语互含 (语义包含)	保留信息量更大 (更长) 的宾语
Supersede	互斥谓词 (住址、工作单位、电话、邮箱、状态等)	旧版本转 Historical 并记录失效时间, 新版本接替
KeepBoth	有冲突但无法判定	并存, 等待后续证据
Reject	输入校验失败 (含敏感值、schema 非法)	拒绝入库

被取代的旧事实不删除, 转为 **Historical** 状态并记录 `valid_to` 时间; `fact_history()` 可回放任一事实的完整演变史, 与偏好版本链的设计一致。

3.2.3 关联检索

检索采用「字段匹配 + 关键词 + 关联图 + 状态」的加权打分:

$$\text{score}(q, f) = 4.0 [\text{字段全匹配}] + 1.0 n_{\text{kw}}(q, f) + 1.5 n_{\text{assoc}}(f) + 0.5 [f \in \text{Active}] + w_c \cdot \text{conf}(f) \quad (1)$$

其中 n_{kw} 为查询词命中数, n_{assoc} 为命中条目经关联边可达的证据数, `conf` 为置信度。查询词同样经过同义归一化, 缓解中文同义表述导致的漏检。语义级检索 (向量近邻) 由第 3.4 节的 RAG 子系统承担, 两者互补。

3.2.4 可复用模板生命周期

模板沉淀遵循「证据先行、人审把关」原则 (表 8): 先以 `register_template` 注册为 **Draft** 状态; 随后通过 `record_template_result` 挂接真实执行片段作为证据; 满足**证据数** ≥ 5 、**成功率** ≥ 0.8 、**人工复核**三条件方可激活为 **Active**; 证据所依赖的事实被遗忘时自动级联降级为 **Retired**。

表 8: 模板状态机

状态	进入条件
Draft	<code>register_template</code> 注册
Active	证据 ≥ 5 且成功率 ≥ 0.8 且人工复核通过 (需权限审批)
Retired	证据级联失效或人工退役

3.3 敏感信息识别与精准遗忘

3.3.1 敏感信息识别与过滤

privacy crate 实现六类检测器（表 9），按三级风险分级，命中内容替换为 [REDACTED:KIND] 占位符后入库。脱敏发生在**所有入库边界**：偏好入库、中期记忆入库、知识库写入，以及服务启动时对磁盘存量数据的全量复扫。

表 9: 敏感信息检测器

类型	校验手段
电子邮箱	格式匹配
手机号	号段与位数规则
身份证号	18 位 + 校验码验证
银行卡号	Luhn 校验
API 密钥	前缀与熵特征
口令字段	字段名启发 (password / token 等)

3.3.2 两阶段精准遗忘协议

遗忘采用「解析—预览—确认—复验」两阶段协议（图 3），全程不可逆操作均需人工确认。




图 3: 两阶段精准遗忘协议

意图解析支持中英文自然语言指令，含两类修饰语法。**排除**语法如「忘掉我的所有住址，**但保留**城市偏好」，排除项不进入删除预案；**来源限定**语法如「只忘掉**来源**：手动配置的」，按数据来源缩小删除范围。

删除预案 (DeletionPlan) 含脱敏预览、预案哈希与 5 分钟生存期；确认时校验哈希防篡改，物理删除事实、关联边与孤儿片段，级联退役受影响模板，随后**重读磁盘验证残留数为零**，最后写入不含任何内容线索的审计记录。无法唯一确定删除目标的模糊指令（如「忘掉一些东西」）会被安全拒绝。forget_confirm 与 activate_template 操作在权限层强制一次性人工审批。

3.4 端侧语义检索：可插拔嵌入与轻量向量库

3.4.1 可插拔嵌入后端

嵌入能力抽象为 `Embedder trait`，按配置在三种后端间切换（表 10），消费方代码不感知差异。

表 10: 嵌入后端

后端	形态	用途
<code>remote</code>	OpenAI 兼容 HTTP 服务	开发期 / 有网络环境
<code>local</code>	内置哈希嵌入器，零依赖离线运行	端侧基线，无网络可用
<code>kylin</code>	银河麒麟 embedding SDK（本机服务形态）	麒麟环境部署

`local` 基线采用特征哈希嵌入：拉丁词 + 中文二元组 (bigram) 分词后，经 FNV-1a 64 位哈希投射到固定维度（默认 384 维），哈希导出符号位，向量 L2 归一化。该方案完全确定性、离线、无模型文件，适合端侧兜底；其局限是仅捕获词法重叠，语义近邻能力有限（优化方向见 §9）。

3.4.2 轻量化向量存储

向量库采用单文件 JSON 持久化与内存态线性扫描，轻量化体现在三个方面。**int8 标量量化**将每向量按绝对值最大值缩放为 int8 存储，查询以整数点积累加（i32 精度），内存占用降为浮点的四分之一，重启后自相似度 > 0.99 （有测试断言）；**v2 信封格式**在文件头记录版本、量化模式与维度，v1 旧格式透明迁移；**维度防护**则将与库内维度不一致的写入与查询显式拒绝，避免静默污染。

检索为 $O(n \cdot d)$ 余弦线性扫描 + 全排序取 top- k 。在端侧典型知识库规模 ($10^3 \sim 10^4$ 条、 $d = 384$) 下，单次扫描为千万级浮点乘加，理论耗时远低于赛题 500ms 上限；分规模实测数据（P50 / P95）**【TODO：检索延迟实测：库规模 1k / 10k / 100k】**。

4 记忆流转机制：与短期、中期记忆的交互逻辑

本章对应赛题要求（6）：兼容与记忆模块中短期、中期记忆间的数据流转。

4.1 短期 → 中期：压缩退役网关

会话上下文接近窗口上限时触发压缩（compaction）。被退役的消息并不直接丢弃，而是经过 **上下文网关**（ContextGate）抽取为中期记忆记录（图 1）。网关的确定性实现 RuleBasedGate 按表 11 的规则识别五类记录。

记录重要性按类型赋默认值（表 12），与压缩摘要策略的优先级一致；同一次转换内按键去重（后写覆盖），单次产出上限 64 条，防止压缩风暴撑爆存储。

表 11: ContextGate 抽取规则

退役消息来源	记录类型	触发条件
用户文本消息	Task	有效内容 ≥ 8 字符，首句作为任务目标
助手文本消息	Decision	内容含决策关键词（决定 / decision 等）
工具调用入参	FileState	入参含路径型字段（path 等）
工具执行结果	ErrorResolution	结果内容含错误关键词
压缩摘要	StateSnapshot	压缩发生即产出

表 12: 记录类型默认重要性（0-100）

记录类型	默认重要性
Decision	80
StateSnapshot	75
ErrorResolution	70
Task	60
FileState / Fact	50 / 40

4.2 中期记忆存储接口

中期记忆库实现 `MidTermStore` 接口：`upsert`（按键替换）、`get`、`delete`、`query`（多条件 AND 过滤，按时间新到旧排序）、`count`、`flush`。记录模型 `MemoryRecord` 携带会话来源、消息区间、访问计数与重要性，可无损转换为长期记忆的 `MemoryEntry` 供既有消费方读取。

4.3 长期记忆注入短期上下文

长期记忆经 `MemoryRegistry`（用户事实提供者 + 向量记忆提供者）在每轮对话构建系统提示词时注入「Persistent Memory」区块，实现长短期记忆闭环（图 1 右侧回边）。

4.4 中期 → 长期晋升

设计上，中期记录应按「重要性 + 访问计数」驱动的晋升机制进入长期记忆库（重要性衰减与淘汰同理）。当前实现状态如下：短期 → 中期、长期 → 短期两条路径已实现；中期 → 长期晋升与中期淘汰 **【TODO: 晋升 / 淘汰机制实现】**；中期记忆查询接入提示词注入 **【TODO: 中期记忆读路径接入 `MemoryRegistry`】**。

4.5 偏好与知识管道的流转关系

偏好库与知识库不经过中期库，而是由 agent 主循环直接驱动：工具每次执行后，结果即时流入偏好提取器；agent 亦可随时经 `kylin_memory` 工具向知识库写入事实、检索、沉淀模板。两条管道均在入库边界完成脱敏 (§3.3)，与三层流转共用同一隐私基础设施。

5 技术实现方案

5.1 实现栈与工程约束

系统以 Rust 实现，全异步 Tokio 运行时，序列化统一为 `serde JSON`。工程约束如下：全链路统一错误类型 `Result<T>`，生产代码零 `unwrap`；公共接口全部 `rustdoc` 文档化，模块有文档级说明，满足赛题源代码可读性要求；工作区按 `crate` 划分（表 3），记忆子系统可整体独立复用于其他 Agent 产品；特性开关（`feature flags`）按需裁剪，端侧可只编译记忆内核 + `local` 嵌入后端。

5.2 Agent 主循环接线点

记忆系统经统一接线模块 `memory_wiring` 接入 agent 主循环（表 13），对主循环零侵入。

表 13: 主循环接线点

时机	管道	目标
每次工具调用后	<code>ingest_tool_execution</code>	偏好库（工具选择偏好提取）
上下文压缩退役时	<code>archive_compacted_context</code>	中期记忆库（网关抽取）
系统提示词构建时	<code>MemoryRegistry</code>	长期记忆注入（Persistent Memory 区块）
会话启动时	工具注册	<code>kylin_memory</code> / <code>RagTool</code> 挂载
服务启动时	存量复扫	磁盘记忆全量脱敏校验

5.3 知识记忆工具面

agent 通过 `kylin_memory` 工具操作知识库，九个操作覆盖写入、检索、模板与遗忘全流程（表 14）；其中 `forget_confirm` 与 `activate_template` 受权限层强制人工审批。

表 14: kylin_memory 工具操作

操作	功能
store_fact	写入 SPO 事实（触发冲突判定与脱敏校验）
search	关联检索（加权打分排序）
register_template	注册 workflow 模板（Draft 状态）
record_template_result	为模板挂接真实执行证据
activate_template	激活模板（三条件门槛 + 人工审批）
find_templates	检索可用模板
privacy_scan	敏感信息扫描
forget_preview	遗忘预案预览（DeletionPlan）
forget_confirm	确认执行遗忘（哈希校验 + 残留复验）

5.4 配置面

记忆与检索行为均由工作区配置驱动（表 15），无需改码即可切换端侧 / 云端 / 麒麟形态。

表 15: 关键配置项

配置项	默认值	说明
rag_enabled	false	是否启用 RAG 工具
embedding_backend	remote	remote / local / kylin
embedding_model	—	嵌入模型名
embedding_base_url	—	remote 后端服务地址
kylin_embedding_endpoint	http://127.0.0.1:18080/v1	麒麟 SDK 服务端点
embedding_dimension	384	向量维度（库内强制一致）
rag_quantization	none	none / int8
rag_chunk_size / rag_chunk_overlap	—	切块参数
rag_top_k	—	检索返回条数

5.5 质量保障

记忆子系统建立了三层测试：模块单元测试（知识记忆服务 14 个、偏好提取与版本化 25 个、隐私检测 3 个等）、跨 crate 集成指标测试（11 个，§7.5）、以及全工作区回归（cargo test --features full）。2026-09-13 集成指标测试运行结果为 **11 通过 / 0 失败**。

6 端侧部署与银河麒麟适配

6.1 端侧轻量化设计

端侧轻量化体现在四个方面。**零外部服务依赖**：除可选的嵌入服务外，系统不需要数据库、消息队列或 GPU，local 嵌入后端零模型文件、完全离线。**轻量存储**：全部状态为单文件 JSON + int8 量化向量，内存与磁盘占用小，人可直接检视与备份。**确定性算法**：偏好提取 / 冲突处理 / 遗忘判定均为规则与统计阈值，无常驻模型推理开销。**按需裁剪**：feature flags 支持只保留记忆内核的最小端侧构建。

6.2 银河麒麟 embedding SDK 接入

kylin 嵌入后端当前按「麒麟 SDK 以本机 OpenAI 兼容服务进程形态提供」接入（默认端点 `http://127.0.0.1:18080/v1`）。针对 SDK 交付形态的可能变化，系统预留了无侵入的升级路径（表 16）：由于嵌入能力收敛在 `Embedder trait` 之后，任何形态变化只影响 `KylinEmbedder` 单个文件的内部实现。

表 16: 麒麟 SDK 交付形态与升级路径

SDK 形态	适配方式
本机 HTTP 服务（OpenAI 兼容）	现有后端直接可用，仅改端点配置
C FFI 动态库	重写 <code>KylinEmbedder</code> 内部加载逻辑，接口面不变
嵌入维度不同	维度防护显式拒绝混用，重建向量索引后重新注入

与麒麟 SDK 的真机联调记录 **【TODO：麒麟 embedding SDK 真机联调（SDK 到货后执行）】**。

6.3 安装部署指南

前置依赖：Rust 稳定版工具链；可选的嵌入服务（remote 形态或麒麟 SDK 服务）。

构建与运行：

```
# 构建（无默认特性，按需启用）
cargo build --features full
# 运行（TUI / HTTP 服务）
cargo run --features full
cargo run --features full -- --server 8080
```

端侧启用麒麟嵌入 + int8 量化的最小配置（工作区 `.amadeus/` 下）：

```
{
  "rag_enabled": true,
  "embedding_backend": "kylin",
  "kylin_embedding_endpoint": "http://127.0.0.1:18080/v1",
```

```
"embedding_dimension": 384,
"rag_quantization": "int8",
"rag_top_k": 5
}
```

运行时目录 `.amadeus/`（表 4）随首次运行自动创建。

6.4 操作说明

记忆操作经 agent 的 `kylin_memory` 工具以自然语言或结构化指令完成，典型示例：

```
{"operation": "store_fact", "subject": "user",
  "predicate": "住址", "object": "南京市", "context": "工作信息"}

{"operation": "search", "query": "住址"}

{"operation": "forget_preview",
  "instruction": "忘掉我的所有住址，但保留城市偏好"}
```

遗忘操作先预览预案、再经人工审批确认（§3.3）；模板激活同理。

6.5 银河麒麟桌面操作系统适配测试报告

记忆子系统全部依赖（Tokio、serde、reqwest 等）均原生支持 Linux / 国产 CPU 架构，代码中不含平台专有调用，具备跨平台适配基础。正式适配测试记录如表 17。

表 17: 银河麒麟适配测试环境与结果

项目	记录
操作系统版本	TODO
内核版本 / CPU 架构	TODO
构建工具链版本	TODO
功能测试结果	TODO
性能指标结果	TODO

【TODO：银河麒麟桌面 OS 环境完成安装部署与全量回归，出具适配测试报告】

7 效果验证报告

7.1 评测指标定义与口径

四项核心指标的评测口径定义如表 18，全部指标在标注数据集上以自动化脚本计算，可复现。

表 18: 评测指标定义

指标	目标值	口径定义
偏好提取准确率	$\geq 85\%$	系统提取的偏好与人工标注偏好（类别 + 内容 + 场景）的一致率
知识检索召回率	$\geq 85\%$	标注相关的知识条目出现在 top- k ($k = 5$) 结果中的比例 (Recall@5)
知识检索响应时间	$\leq 500\text{ms}$	端到端检索耗时 (含打分排序) 的 P50 / P95
知识冲突处理正确率	$\geq 88\%$	六动作判定结果与人工标注期望动作的一致率

7.2 标准化测试数据集说明

评测数据集由三个子集构成。**偏好标注集**收录工具调用执行序列（任务—工具—成败—延迟）、用户行为序列与配置项，由双人独立标注「应提取出的偏好」并仲裁分歧，用于偏好提取准确率。**知识检索集**为查询—相关知识条目对（含同义改写、多关联边、历史版本干扰项），用于 Recall@5 与检索延迟。**冲突判定集**为新旧事实对附期望处置动作（六动作全覆盖，含互斥谓词与上下文一致性边界情形），用于冲突处理正确率。

数据集规模、来源与标注一致性（双人一致率 / Kappa）**【TODO: 评测数据集构建完成并冻结版本】**。

7.3 量化指标结果

表 19: 核心指标实测结果

指标	目标值	实测值	结论
偏好提取准确率	$\geq 85\%$	TODO	TODO
知识检索召回率 (Recall@5)	$\geq 85\%$	TODO	TODO
检索响应时间 P50 / P95	$\leq 500\text{ms}$	TODO	TODO
冲突处理正确率	$\geq 88\%$	TODO	TODO

【TODO: 在冻结数据集上运行四项指标评测脚本并填入本表；未达标项在第 9 章给出优化方向】

7.4 对比实验设计（消融）

为量化各机制的贡献，设计如下消融对比（表 20），实验组仅关闭单一机制，其余条件一致。

表 20: 消融实验设计与结果

实验组	检验假设	结果
完整方案	—	TODO
去版本化（仅保留最新版本）	版本链对回溯 / 审计的贡献	TODO
去冲突融合（新事实一律 Add）	六动作机制对正确率的贡献	TODO
去关联边（检索不加关联分）	关联图对召回的贡献	TODO
去同义归一化	中文同义对召回的贡献	TODO
int8 vs 全精度	量化对检索质量与延迟的影响	TODO

7.5 功能验收测试

跨 crate 集成指标测试共 11 个，2026-09-13 以 `cargo test --features full` 运行，**全部通过**（表 21），覆盖赛题内容要求 (3)(4)(5) 的核心闭环。

模块级单元测试另有数十个（知识记忆服务 14、偏好提取与版本化 25、隐私检测 3 等），覆盖阈值边界、版本回滚、跨场景解析与校验码算法。

7.6 历史基线与重测计划

2026 年 5 月曾以 LoCoMo 长对话数据集（10 会话 / 189 问答对）对早期 RAG 链路做过一次评测（当时为 remote 嵌入后端、LLM 问答 F1 口径）：RAG 模式 $F1 = 39.2\%$ 、全上下文 $F1 = 54.0\%$ ，其中单跳 60.4% 、多跳 25.0% 、时序 12.2% ，平均查询耗时 $0.02s$ 。

需要说明：该口径度量的是问答生成质量而非检索召回率，且早于 local / kylin 后端与 int8 量化的引入，不能直接对标赛题指标，仅作为演进基线保留。以本方案口径（Recall@5, local / kylin 后端）的重测 **【TODO: LoCoMo 数据集按 Recall 口径重测】**。

7.7 检索延迟实测方案

延迟实测按库规模 $\times$ 量化模式网格执行（1k / 10k / 100k 条，int8 / 全精度， $d = 384$ ），每组 1000 次查询取 P50 / P95，测试机规格与结果 **【TODO: 延迟网格实测并填入 assets/metrics-latency.png】**。

8 真实场景应用案例

8.1 场景设计：开发助手日常使用（办公自动化）

选取「基于 OS Agent 的开发 / 办公自动化助手」作为真实落地场景，覆盖三类记忆能力的完整闭环。偏好沉淀与复用方面，用户在多轮会话中反复于同类任务选择某一工具、要求简洁输出格式，系统从工具执行结果与用户行为中自动提取工具选择与输出

表 21: 集成指标测试 (11 / 11 通过)

测试	验证点	结果
indicator_3_conflict_search_and_history_form_a_closed_loop	冲突接替—检索—版本史闭环	通过
indicator_3_template_activation_requires_five_examples_review_and_eighty_percent_success	模板激活三条件门槛	通过
indicator_3_default_agent_registers_kylin_memory_without_legacy_registry	工具默认注册	通过
indicator_5_rejects_ambiguous_and_non_deletion_requests	模糊遗忘指令安全拒绝	通过
indicator_5_sensitive_information_is_redacted_at_scan_and_storage_boundaries	扫描与入库双边界脱敏	通过
indicator_5_precise_forgetting_preserves_exclusions_and_requires_confirmation	排除项保留 + 强制确认	通过
indicator_4_local_hash_embedder_is_deterministic_normalized_and_offline	local 后端确定性 / 归一化 / 离线	通过
indicator_4_int8_quantized_store_survives_restart	int8 量化重启自相似度 > 0.99	通过
indicator_4_rag_tool_ingest_and_query_end_to_end	注入—检索端到端	通过
indicator_4_backend_selection_from_config	后端配置切换	通过
indicator_4_agent_registers_rag_tool_when_enabled	RAG 工具按配置挂载	通过

风格偏好，跨会话、跨场景（终端场景 / 文档场景）持续生效；用户手动修改配置后，偏好经版本化更新并可回溯。知识沉淀与智能调用方面，一次完整的「构建—排错—修复」流程被沉淀为可复用模板（含前置条件与步骤），五次真实执行证据且成功率达标并经人工复核后激活，后续同类故障一键复用；新旧事实（如项目构建参数变更）经冲突处理自动接替，版本史可查。安全合规方面，记忆过程中出现的手机号、邮箱等被自动脱敏；演示「忘掉我的所有住址，但保留城市偏好」——排除项保留、目标数据物理删除、磁盘零残留。

8.2 实测记录

案例执行记录、关键步骤截图与启用 / 关闭记忆的前后对比 **【TODO：真实场景案例执行并记录（步骤截图、前后对比、用户反馈）】**。

效果演示视频 **【TODO：录制偏好捕捉、知识整合、检索复用三段演示视频】**。

8.3 应用价值

该场景直接对应赛题「办公自动化、智能协作、个性化助手」的应用方向：偏好记忆减少重复指令与工具选择成本，知识模板把一次性排错经验转化为可复用资产，精准遗忘满足个人信息保护的合规要求。量化收益（任务完成时间缩短比、指令次数下降比）**【TODO：案例量化收益统计】**。

9 总结与优化方向

9.1 已完成工作

截至本报告撰写时，系统已完成三层记忆架构（短期 / 中期 / 长期）与双库（偏好 / 知识）落地，全部状态文件化、零外部服务依赖；实现多源偏好提取三路提取器、只追加版本化、非破坏回滚、按时间点回溯与基于场景相似度的跨场景复用；建成 SPO 事实版本链、同义归一化、六动作冲突处理、关联加权检索与证据先行的模板生命周期；落实六类敏感信息检测、全入库边界脱敏与两阶段精准遗忘（预案—审批—物理删除—残留复验—审计）；交付可插拔嵌入三后端（remote / local / kylin）、int8 量化向量库与 v1/v2 格式迁移；记忆子系统已接入 agent 主循环，11 个集成指标测试与数十个模块单元测试通过（2026-09-13 运行）。

9.2 待完成事项

以下事项均在前文以红色 TODO 标注，此处按工作类别汇总。（1）**【TODO：标准化评测数据集三子集构建与冻结 (§7.2)】**；（2）**【TODO：四项性能指标实测与消融实验 (§7.1)】**；（3）**【TODO：检索延迟网格实测 (§7.1)】**；（4）**【TODO：用户**

行为 / 手动配置管道接入 agent 主循环 (§3.1)】；(5) 【TODO: 偏好注入系统提示词, 形成个性化闭环演示 (§3.1)】；(6) 【TODO: 中期 → 长期晋升与中期淘汰机制 (§4)】；(7) 【TODO: 麒麟 embedding SDK 真机联调 (§6.2)】；(8) 【TODO: 银河麒麟桌面 OS 适配测试报告 (§6)】；(9) 【TODO: 真实场景案例实测记录与演示视频 (§8)】；(10) 【TODO: LoCoMo 数据集按 Recall 口径重测 (§7)】。

9.3 后续优化方向

后续优化沿四个方向推进。**本地神经嵌入**: 以小型中文嵌入模型 (int8 量化) 替换哈希基线, 提升语义召回上限, 同时保持离线与低资源占用。**混合检索排序**: 结构化加权检索与向量近邻的融合排序, 兼顾精确字段匹配与语义泛化, 知识库规模增长后引入轻量 ANN 索引。**遗忘意图的 NLU 扩展**: 在保留规则式安全护栏的前提下, 扩展意图解析的概念覆盖面。**中期记忆生命周期**: 重要性衰减、访问计数驱动晋升与淘汰, 补全三层流转的最后一环。