

OS Agent 记忆模块用户手册

偏好记忆 · 知识记忆 · 精准遗忘

题目编号：XA-202612

发榜单位：麒麟软件有限公司

参赛单位：【TODO：学校 / 单位全称】

队伍名称：【TODO：队伍名称】

版本 0.1 · 2026 年 9 月

目录

1	快速上手	2
1.1	记忆模块能为你做什么	2
1.2	系统要求与安装	2
1.3	五分钟体验记忆闭环	3
2	配置指南	3
2.1	选择嵌入后端	4
2.2	银河麒麟环境部署	4
3	偏好记忆	5
3.1	偏好是如何学到的	5
3.2	版本、回滚与跨场景	5
3.3	管理你的偏好	5
4	知识记忆	5
4.1	写入与检索知识	5
4.2	新旧知识冲突时会发生什么	6
4.3	把成功流程沉淀为模板	6
5	隐私保护与精准遗忘	6
5.1	敏感信息的自动保护	6
5.2	用一句自然语言遗忘	7
5.3	数据的所有权与彻底清除	7
6	记忆的层级与流转	7
6.1	三层记忆如何协作	7
6.2	中期记忆的读取与晋升	8
7	排障与常见问题	8
7.1	常见问题	8
7.2	诊断信息收集	8

1 快速上手

1.1 记忆模块能为你做什么

OS Agent 的记忆模块让助手在使用过程中**越用越懂你**。它由两个互补的记忆库组成。偏好记忆持续观察你的操作习惯：当你在同类任务中总是选择同一个工具、反复要求某种输出格式、或明确修改过某项配置时，系统会自动把这些倾向沉淀为偏好，在之后的会话中直接沿用，不再需要你每次重复交代。知识记忆则是一个可追溯的事实库与模板库：你与助手确认过的事实（项目参数、联系方式、环境信息）以结构化三元组存储，新旧信息冲突时自动接替并保留历史版本；一次完整的操作流程（例如「构建—排错—修复」）在积累足够执行证据并经你确认后，可以固化为可复用的工作流模板。

所有记忆数据都以普通 JSON 文件保存在你的工作区 `.amadeus/` 目录下，不依赖任何数据库或云服务，你可以随时用文本编辑器直接查看、备份或删除。涉及个人敏感信息的内容（手机号、身份证号、银行卡号、邮箱、密码、API 密钥）在写入记忆前会被自动替换为占位符；你也可以随时用一句自然语言让助手「忘掉」指定记忆（见第 5 章）。

1.2 系统要求与安装

系统要求为 Rust 稳定版工具链（`rustup` 安装即可），可选准备一个嵌入服务用于语义检索（不准备也不影响其余功能，系统会退回内置离线嵌入，见 §2.1）。在仓库根目录执行：

```
cargo build --features full
cargo run --features full # 启动终端交互 (TUI)
cargo run --features full -- --server 8080 # 或启动 HTTP 服务
```

首次运行后，助手会在当前工作区自动创建 `.amadeus/` 目录并初始化全部记忆文件。各文件的含义见表 1，日常使用中你通常不需要直接修改它们。

表 1: 记忆数据文件一览（`.amadeus/` 目录）

文件	内容
<code>preferences.json</code>	偏好记忆：学到的偏好及其历史版本
<code>structured_memory.json</code>	知识记忆：事实、关联、模板
<code>mid_term_memory.json</code>	中期记忆：跨会话的任务与决策记录
<code>memory.json</code>	长期事实记忆（注入对话上下文）
<code>rag_index.json</code>	语义检索的向量索引

在银河麒麟桌面操作系统上的部署要点与适配说明见 §2.2。

1.3 五分钟体验记忆闭环

安装启动后，你可以按下面的顺序快速体验记忆模块的核心能力。

第一步，**让系统学到偏好**。用自然语言让助手完成几个同类任务并指定同一个工具，例如连续两次要求「用 ripgrep 统计 xxx」。系统在工具执行成功且样本充足后自动生成工具选择偏好，之后同类任务会优先使用该工具。你也可以直接告诉助手「以后输出都用简洁格式」，明确的指令会立即成为高置信度偏好。

第二步，**沉淀一条知识**。对助手说「记住：我的项目构建参数是 xxx」。助手会调用 `kylin\_memory` 工具把这条信息写成结构化事实。之后你随时可以问「我的构建参数是什么」，助手会从知识库检索作答。

第三步，**验证冲突接替**。接着说「更新一下：构建参数改为 yyy」。系统不会新旧混杂，而是把旧值标记为历史版本、以新值接替；你可以要求助手「查一下这条事实的修改历史」看到完整的版本链。

第四步，**体验精准遗忘**。说「忘掉我的构建参数，但保留项目名称」。助手会先给出一份删除预览（列出将删除的内容与保留的内容），等你明确确认后才真正删除，并在删除后自动校验磁盘上已无残留。

2 配置指南

记忆行为由工作区配置文件控制，全部配置项见表 2。修改配置后重启会话生效；切换嵌入后端或维度后，需要删除 `rag_index.json` 并重新注入文档（不同模型的向量不可混用，系统会显式拒绝维度不一致的写入而不是悄悄污染结果）。

表 2: 记忆与检索配置项

配置项	默认值	说明
<code>rag_enabled</code>	<code>false</code>	是否启用语义检索工具
<code>embedding_backend</code>	<code>remote</code>	嵌入后端: <code>remote</code> / <code>local</code> / <code>kylin</code>
<code>embedding_model</code>	—	<code>remote</code> 后端的模型名
<code>embedding_base_url</code>	—	<code>remote</code> 后端服务地址
<code>kylin_embedding_endpoint</code>	<code>http://127.0.0.1:18080/v1</code>	麒麟 SDK 服务端点
<code>embedding_dimension</code>	<code>384</code>	向量维度，库内强制一致
<code>rag_quantization</code>	<code>none</code>	<code>int8</code> 可将向量内存占用降为 1/4
<code>rag_chunk_size</code>	—	文档切块大小
<code>rag_chunk_overlap</code>	—	相邻切块重叠量
<code>rag_top_k</code>	—	检索返回条数

2.1 选择嵌入后端

三种后端面向三种使用环境，配置其一即可，切换不影响其他功能。

remote：语义质量最好，适合开发与联网环境。将 `embedding_backend` 设为 `remote`，并提供一个 OpenAI 兼容的嵌入服务地址与模型名，例如：

```
{
  "rag_enabled": true,
  "embedding_backend": "remote",
  "embedding_base_url": "http://127.0.0.1:1113/v1",
  "embedding_model": "bge-small-zh-v1.5",
  "embedding_dimension": 512
}
```

local：完全离线、零依赖的内置方案，不需要任何模型文件或网络。向量由文本特征哈希生成，检索效果以词面重合为主，适合作为端侧兜底。启用配置如下，建议同时开启 `int8` 量化以降低内存占用：

```
{
  "embedding_backend": "local",
  "rag_quantization": "int8"
}
```

kylin：面向银河麒麟桌面操作系统的部署形态，连接本机运行的麒麟 `embedding SDK` 服务（OpenAI 兼容接口）。配置见 §2.2。

2.2 银河麒麟环境部署

在银河麒麟桌面操作系统上，推荐使用 `kylin` 后端以获得国产 `SDK` 的语义嵌入能力。部署步骤为：先在本机启动麒麟 `embedding SDK` 服务（默认监听 `127.0.0.1:18080`），再按下例配置助手：

```
{
  "rag_enabled": true,
  "embedding_backend": "kylin",
  "kylin_embedding_endpoint": "http://127.0.0.1:18080/v1",
  "embedding_dimension": 384,
  "rag_quantization": "int8"
}
```

若 `SDK` 服务未启动或端口不同，检索类操作会明确报错（网络连接失败），不会静默降级；此时可临时切换 `local` 后端保持功能可用。麒麟 `SDK` 的实际交付形态若与本节假设不同（例如以动态库形式提供），升级只需要更新嵌入适配层，你的配置与数据文件不受影响。`SDK` 服务在不同麒麟版本上的安装与启动方法 **【TODO：麒麟 SDK 实机部署步骤与截图】**。

3 偏好记忆

3.1 偏好是如何学到的

偏好记忆有三个信息来源，它们在后台自动工作，不需要你做任何额外操作。**工具执行结果**是最主要的来源：助手统计你在同类任务中对各工具的使用成败，当某个工具在某类任务上表现出稳定优势（样本充足、成功率高、占比过半）时，生成「这类任务优先用这个工具」的偏好；反之若某工具连续失败，其权重会被降低但不会直接删除，给它留出恢复的余地。**你的明确指令**置信度最高：你说「以后都用简洁格式」「构建前先跑测试」这类话时，会被立即记录为偏好。**行为纠正**同样有效：如果你反复否决助手的某种做法，系统会记录「避免」偏好并削弱与之冲突的旧习惯。

每条偏好都带有置信度，并按类别归档：工具选择、输出风格、安全策略、 workflows、操作习惯与通用偏好。安全敏感操作相关的倾向会单独归入安全策略类，供审批环节参考。

3.2 版本、回滚与跨场景

偏好的每次变化都产生一个新版本，历史版本完整保留。这意味着两件事：其一，你可以随时要求助手「把 xx 偏好回滚到上周的值」，回滚以追加新版本的方式完成，历史不被破坏；其二，你可以要求「看看这条偏好的变化过程」，得到完整的时间线。

偏好还可以绑定**场景**。例如你在终端场景偏好简短输出，在文档撰写场景偏好详尽输出——两者作为同一偏好的不同场景版本并存。当助手在某个场景下没有完全匹配的偏好时，会参考属性最相近场景下已验证的偏好作为起点。在指定时间点回溯「当时生效的是哪个版本」也是支持的，便于排查「行为什么时候变的」这类问题。

3.3 管理你的偏好

你可以用自然语言管理偏好：问「你现在记住了我哪些偏好」列出全部；说「不要再自动用 xx 工具了」删除或降级对应偏好；说「这条偏好在 yy 场景下不适用」调整场景绑定。偏好的读取入口（注入对话上下文）**【TODO：偏好注入提示词接线完成后，补充「验证偏好生效」的操作说明与截图】**。

4 知识记忆

4.1 写入与检索知识

知识记忆以「主语—谓语—宾语」三元组结构存储事实，助手通过 `kylin\_memory` 工具读写。日常使用完全通过自然语言完成。要写入知识，直接说「记住：张三的工作邮箱是 `zs@example.com`」，入库前邮箱会被自动脱敏；要检索，就问「张三的邮箱是什

么」或「查一下和部署相关的记忆」；想了解某条事实的来龙去脉，可以问「这条事实是什么时候改成现在这样的」，助手会展示完整的版本链。

检索时系统同时匹配字段、关键词与知识条目之间的关联关系，并对中文同义表述做归一化（「住址」与「地址」视为同一谓词），因此不必刻意使用与当初写入时完全相同的措辞。需要语义级的模糊检索（例如「找之前聊过的类似问题」）时，助手会改用语义检索工具（第 2 章配置的嵌入后端）。

4.2 新旧知识冲突时会发生什么

当你写入的新事实与已有事实矛盾时，系统按明确的规则处置，而不是简单地覆盖或报错。同一条事实的重复确认会增强其置信度；信息互含时会合并保留更完整的表述；住址、电话、邮箱、工作单位、状态等天然互斥的谓词发生变更时，旧值自动转为**历史版本**并记录失效时间，新值接替当前值；无法自动判定的矛盾则两者并存，等待后续信息澄清。全部处置过程可追溯——每条事实都有完整的版本链，任何时刻的值都可以回放。

4.3 把成功流程沉淀为模板

当某类任务被成功完成过多次（例如同一类构建错误的修复流程），你可以让助手「把这个流程保存为模板」。模板不是立即生效的：它先进入草稿状态，之后每次按此流程执行都会积累一条真实执行证据；当证据满五条、成功率达到八成，并经你人工确认后，模板才被激活供日后复用。这套门槛的目的是防止把偶然成功的做法固化成套路。激活后的模板如果所依据的知识被删除（例如执行了遗忘），会自动退役，避免引用失效的经验。

5 隐私保护与精准遗忘

5.1 敏感信息的自动保护

记忆模块内置六类敏感信息检测：电子邮箱、手机号、身份证号（含校验码验证）、银行卡号（含 Luhn 验证）、API 密钥与口令字段。凡是要写入记忆的内容，无论来自对话、工具结果还是配置，都会先经过检测；命中部分在入库前就被替换为【REDACTED: 类型】占位符，原始值不落盘。这项保护在服务每次启动时还会对已有记忆文件做一次全量复扫，防止历史数据中残留敏感内容。你可以让助手「扫描一下记忆里的敏感信息」主动查看当前的保护状态。

5.2 用一句自然语言遗忘

精准遗忘是你的权利，也是一等公民功能。直接用自然语言向助手下达遗忘指令即可，支持两类修饰语法让指令足够精确：

```
忘掉我的所有住址  
忘掉我的所有住址，但保留城市偏好 # 排除语法  
只忘掉来源是手动配置的偏好 # 来源限定语法
```

遗忘永远不会因为一句话就立即执行。助手首先解析你的意图，生成一份**删除预案**：列出将要删除的每条内容（以脱敏预览的形式）、保留的内容，以及预案摘要。预案在五分钟内有效，你需要明确确认后才会执行。确认时系统校验预案未被篡改，随后物理删除目标数据及其关联，并**重新读取磁盘验证已无任何残留**，最后在审计记录中留下这次操作的事实（记录本身不含被删内容）。涉及删除的确认与 workflow 模板的激活一样，在权限层被强制要求人工审批，代理无法替你越过这一步。

如果指令含糊到无法确定删除范围（例如「忘掉一些东西」），助手会拒绝执行并请你说明具体目标——这是刻意设计的安全行为。目前可被遗忘指令识别的记忆对象覆盖常见类型（住址、城市、电话、邮箱、身份证、偏好等）**【TODO：遗忘意图可识别范围随实现扩展后更新本清单】**。

5.3 数据的所有权与彻底清除

所有记忆都是你工作区里的普通文件，拥有最终控制权：删除 `preferences.json` 即清空全部偏好，删除 `structured_memory.json` 即清空知识库，删除 `rag_index.json` 即清空语义索引。应用卸载不会遗留工作区之外的记忆数据。

6 记忆的层级与流转

6.1 三层记忆如何协作

助手同时维护三层记忆，它们各司其职。**短期记忆**是当前对话的上下文窗口，容量有限、随会话结束。**中期记忆**在上下文即将溢出时接管：对话中确立的任务目标、做出的决策、改动过的文件、遇到的错误与解决办法，会在压缩时被抽取为结构化记录，跨会话保留。**长期记忆**则是前面章节介绍的偏好库、知识库与语义索引，永久保存并持续注入后续对话。

日常使用中你不需要干预这套流转，但理解它有助于解释两个常见现象。其一，「助手好像忘了很早之前的对话细节」——细节可能还保留在中期记忆中，只是不在当前窗口里，你可以让助手「查一下之前关于 xx 的记录」主动召回。其二，「压缩之后助手仍记得我决定过什么」——这正是压缩退役网关在起作用，重要决策以高于普通内容的重要性被保留。

6.2 中期记忆的读取与晋升

你可以通过自然语言查询中期记忆，例如「这个会话里我们做过哪些决定」「之前处理 xx 错误的方法是什么」。中期记忆中反复被访问、重要性高的记录，最终应晋升为长期记忆；该晋升机制与淘汰策略的实现进度见 **【TODO：中期记忆晋升机制落地后更新本节操作说明】**。

7 排障与常见问题

7.1 常见问题

检索类操作报网络错误。嵌入服务不可达是最常见原因。请确认所选后端的服务确实在运行：remote 后端检查 `embedding\_base\_url` 指向的服务，kylin 后端检查麒麟 SDK 服务是否监听在 `kylin\_embedding\_endpoint`。临时应急可切换 local 后端，它完全离线、始终可用。

切换嵌入后端后检索结果为空或报维度错误。不同后端的向量维度可能不同，向量不可跨模型混用。删除工作区中的 `rag_index.json` 并重新注入文档即可，系统的显式报错正是在防止新旧向量被静默混合。

偏好没有生效。偏好需要足够的样本才会形成：同一任务同一工具至少两次成功、且成功率达八成。明确的语言指令则立即生效。若你怀疑某条偏好的判断，可以要求助手展示该偏好的置信度与版本历史。

遗忘指令被拒绝。多是指令范围不够明确。请使用第 5 章的修饰语法指明对象与保留项；涉及多种同类信息时，先执行「预览」确认范围再确认删除。

模板无法激活。检查三个条件是否同时满足：真实执行证据满五条、成功率达八成、人工确认。前两项由系统统计，可以在助手中查询模板当前的证据计数。

7.2 诊断信息收集

提交问题反馈时，请附上以下信息：操作系统与版本、Rust 工具链版本（`rustc -V`）、`.amadeus/` 下各记忆文件的大小、以及所使用的嵌入后端配置（隐去服务地址中的密钥）。运行日志位于仓库 `logs/` 目录 **【TODO：日志路径与日志级别开关确认后补充具体说明】**。

在银河麒麟桌面操作系统上的已知适配问题与解决进展汇总于 **【TODO：麒麟适配测试后补充已知问题清单】**。